

LAPORAN TEKNIS KOMPREHENSIF
SAWIT (Sahabat Duwit): Aplikasi Keuangan Digital yang Dirancang untuk Generasi Z
dalam Mengelola Keuangan Tanpa Pusing
CC26-PSU329

List Anggota:

1. (CFCC114D6Y1317) - (Maxwell Avinda Rumahorbo) - (Fullstack Web Developer)
2. (CFCC114D6Y1958) - (Rony Reynaldy Pangaribuan) - (Fullstack Web Developer)
3. (CDCC008D6X1776) - (Geisha Patricia Sihotang) - (Data Scientist)
4. (CDCC008D6X2381) - (Gabriela Anastasia Putri Sugiarto) - (Data Scientist)
5. (CACC297D6Y2197) - (Stefano Garrent Khristiawan) - (AI Engineer)
6. (CACC008D6Y1427) - (Bonaventura Gerardo) - (AI Engineer)

Tema: Revolusi Teknologi Keuangan (Fintech) untuk Generasi Muda

1. Business Understanding

1.1 Latar Belakang Bisnis

Perkembangan teknologi digital telah mempermudah berbagai aktivitas keuangan, mulai dari pembayaran hingga transaksi belanja daring. Namun, kemudahan tersebut juga diiringi dengan meningkatnya tantangan dalam pengelolaan keuangan pribadi, khususnya bagi Generasi Z yang memiliki gaya hidup serba digital dan cenderung konsumtif. Berdasarkan Survei Nasional Literasi dan Inklusi Keuangan (SNLIK) 2024 yang dirilis oleh OJK, tingkat literasi keuangan Generasi Z masih berada pada angka 44,04%, menunjukkan bahwa pemahaman mengenai pengelolaan keuangan, perencanaan finansial, dan investasi masih perlu ditingkatkan. Kondisi ini menyebabkan banyak generasi muda mengalami kesulitan dalam mengontrol pengeluaran, menabung secara konsisten, serta mencapai tujuan keuangan jangka panjang. Oleh karena itu, SAWIT (Sahabat Duwit) hadir sebagai aplikasi keuangan digital yang membantu Generasi Z mencatat dan menganalisis transaksi, memperoleh rekomendasi keuangan yang personal, serta meningkatkan literasi investasi melalui pendekatan berbasis data dan kecerdasan buatan.

1.2 Permasalahan Bisnis

Berdasarkan permasalahan dan kebutuhan pengguna yang telah diidentifikasi, dirumuskan beberapa pertanyaan bisnis sebagai landasan pengembangan solusi SAWIT bagi Generasi Z.

1. Bagaimana membantu Generasi Z memahami pola pemasukan & pengeluaran mereka secara lebih efektif?
2. Bagaimana membantu Generasi Z mengelola dan memantau transaksi keuangan sehari-hari secara lebih mudah, akurat, dan terstruktur?
3. Bagaimana memberikan rekomendasi keuangan yang personal dan relevan berdasarkan kondisi serta perilaku pengeluaran Generasi Z?
4. Bagaimana meningkatkan literasi investasi dan pemahaman investasi Generasi Z melalui informasi yang sederhana, informatif, dan mudah dipahami?

1.3 Cakupan Proyek

SAWIT (Sahabat Duwit) dikembangkan sebagai aplikasi berbasis web yang bertujuan membantu Generasi Z dalam mengelola keuangan pribadi secara lebih terstruktur dan terencana. Proyek ini mencakup enam fitur utama, yaitu

- 1) Auto Categorization berbasis Artificial Intelligence yang mampu mengelompokkan transaksi secara otomatis ke dalam kategori pengeluaran tertentu,
- 2) AI Recommendation & Early Warning yang memberikan rekomendasi keuangan personal berdasarkan pola pengeluaran pengguna,
- 3) Dashboard Analytics yang menyajikan visualisasi kondisi keuangan pengguna,
- 4) Subscription Tracker untuk membantu pengguna memantau dan mengelola pengeluaran rutin atau langganan,
- 5) Wishlist Calculator yang mendukung perencanaan target keuangan melalui perhitungan kebutuhan tabungan, serta
- 6) Investment Corner yang menyediakan informasi dan edukasi investasi berbasis data saham secara sederhana dan mudah dipahami.

Ruang lingkup proyek ini dibatasi pada pengelolaan dan analisis keuangan pribadi sehingga **tidak mencakup** integrasi langsung dengan rekening bank maupun dompet digital, transaksi jual beli saham, deteksi otomatis layanan langganan melalui email, serta pemrosesan Optical Character Recognition (OCR) pada struk fisik. Dengan demikian, SAWIT berperan sebagai platform pendukung pengelolaan keuangan dan peningkatan literasi finansial, bukan sebagai layanan transaksi keuangan.

Pengembangan sistem dilakukan menggunakan React.js pada sisi frontend yang dideploy melalui Vercel, Express.js dan FastAPI pada sisi backend yang dijalankan menggunakan Railway, serta PostgreSQL yang dikelola melalui Supabase sebagai basis data utama. Selain itu, TensorFlow dan Scikit-learn digunakan untuk mendukung pengembangan model kecerdasan buatan yang berfungsi melakukan kategorisasi transaksi secara otomatis.

2. Data Understanding

2.1 Data Kategorisasi Pengeluaran

Untuk membangun dataset kategorisasi transaksi, data dikumpulkan melalui proses *web scraping* menggunakan **Instant Data Scraper** pada berbagai platform publik yang merepresentasikan aktivitas pengeluaran sehari-hari. Pengambilan data dilakukan pada seluruh halaman yang tersedia serta berbagai filter pencarian (seperti *Populer*, *Terbaru*, dan *Terlaris*) untuk memperoleh variasi data yang lebih beragam. Data yang dikumpulkan difokuskan pada nama produk, layanan, atau tempat, tanpa menyertakan informasi harga, karena tujuan utama model adalah mengklasifikasikan deskripsi transaksi ke dalam kategori pengeluaran.

Sumber	Data yang Dikumpulkan	Kategori
Shopee	Nama produk dari berbagai kategori produk pada seluruh halaman dan filter pencarian	Entertainment, Konsumsi (Makanan & Minuman), Tagihan (Pulsa, Paket Data, Voucher), Kesehatan
Tokopedia	Nama layanan digital, produk pembayaran, dan layanan berlangganan	Tagihan, Langganan

GoFood	Nama makanan, minuman, restoran, dan menu	Konsumsi
Traveloka	Nama layanan transportasi, hotel, tiket perjalanan, serta tiket atraksi wisata	Transportasi, Entertainment
Google Maps	Nama tempat hiburan dan destinasi wisata seperti bioskop, karaoke, taman hiburan, dan objek wisata	Entertainment
Astronauts	Nama produk gaya hidup dan kebutuhan non-esensial	Entertainment
K24Klik	Nama produk kesehatan dan kebutuhan farmasi	Kesehatan

Selain data hasil scraping, dataset juga diperkaya menggunakan **data sintetis berbasis AI** yang mensimulasikan berbagai deskripsi transaksi yang umum ditulis pengguna dalam kehidupan sehari-hari, seperti “*beli kopi susu*”, “*isi bensin motor*”, “*langganan Spotify*”, atau “*nonton bioskop*”. Pendekatan ini dilakukan untuk meningkatkan variasi data serta membantu model mengenali berbagai bentuk penulisan transaksi yang berbeda.

Setelah proses pengumpulan dan pembersihan data, setiap entri transaksi kemudian dikelompokkan ke dalam enam kategori pengeluaran yang digunakan sebagai label pada proses pelatihan model:

- **Konsumsi:** makanan, minuman, dan kebutuhan harian.
- **Transportasi:** biaya mobilitas dan perjalanan, termasuk transportasi umum, kendaraan, tiket perjalanan, dan akomodasi.
- **Tagihan:** pembayaran rutin seperti listrik, air, internet, pulsa, dan layanan utilitas lainnya.
- **Langganan:** layanan digital berbayar yang bersifat periodik, seperti platform streaming dan aplikasi premium.
- **Entertainment:** hiburan, rekreasi, gaya hidup, pakaian, wisata, bioskop, karaoke, dan kebutuhan non-esensial lainnya.
- **Kesehatan:** obat-obatan, vitamin, suplemen, alat kesehatan, dan kebutuhan farmasi.

2.2 Data Saham LQ45

Data investasi pada SAWIT diperoleh dari dua sumber utama yang disediakan oleh Bursa Efek Indonesia (BEI). Daftar saham yang digunakan sebagai objek analisis berasal dari indeks LQ45 yang diperoleh melalui [halaman Indeks Saham BEI](#). Daftar tersebut digunakan untuk mengumpulkan ticker saham perusahaan yang kemudian dimanfaatkan dalam proses pengambilan data historis saham menggunakan library yfinance.

Selain itu, informasi profil perusahaan diperoleh dari halaman [Profil Perusahaan Tercatat BEI](#). Data yang dikumpulkan meliputi kode saham, nama perusahaan, bidang usaha utama, sektor, subsektor, industri, subindustri, tahun berdiri, dan kantor pusat perusahaan. Informasi ini digunakan untuk mendukung fitur Investment Corner sehingga pengguna dapat memahami karakteristik perusahaan selain hanya melihat pergerakan harga saham.

Selanjutnya, data historis saham seperti Open, High, Low, Close, dan Volume diperoleh melalui library yfinance dengan menggunakan ticker saham LQ45 yang telah dikumpulkan dari



entertainment, konsumsi, transportasi, kesehatan, langganan, serta tagihan. Dataset gabungan ini kemudian digunakan sebagai data mentah yang akan melalui proses pembersihan dan preprocessing pada tahap berikutnya.

2) Data untuk Dashboard Investasi Saham

Data saham diperoleh secara otomatis dari Yahoo Finance menggunakan library `yfinance` pada Python. Proses pengambilan data dilakukan secara terjadwal melalui GitHub Actions setiap hari bursa (Senin–Jumat) setelah penutupan perdagangan saham. Data yang diperoleh mencakup informasi historis harga saham dan disimpan dalam format CSV sehingga siap digunakan untuk proses analisis. Dataset ini dimanfaatkan untuk membangun Dashboard Investasi, menyajikan informasi pergerakan saham, serta mendukung perhitungan statistika deskriptif dan analisis sederhana yang ditampilkan kepada pengguna.

3.2 Data Assessing and Cleaning

1) Data untuk Fitur Auto Categorization

Setelah data transaksi berhasil dikumpulkan, dilakukan proses data assessing untuk mengevaluasi kualitas dan konsistensi data sebelum digunakan dalam pengembangan model klasifikasi. Tahap ini meliputi pemeriksaan struktur data, kesesuaian kategori transaksi, keberadaan data duplikat, nilai kosong (*missing values*), serta konsistensi penulisan nama produk dan sumber data. Selain itu, dilakukan seleksi atribut sehingga hanya variabel yang relevan, seperti *source*, kategori, dan nama produk, yang digunakan pada tahap selanjutnya.

Setelah proses evaluasi selesai, dilakukan data cleaning untuk meningkatkan kualitas data. Tahapan pembersihan meliputi penghapusan data duplikat, penanganan nilai kosong, penyeragaman format penulisan teks, konversi seluruh huruf menjadi huruf kecil (*lowercase*), penghapusan angka, tanda baca, dan spasi berlebih. Selanjutnya dilakukan penghapusan stopwords menggunakan kombinasi stopwords Bahasa Indonesia dari NLTK dan custom stopwords yang disusun berdasarkan kata-kata promosi, istilah pemasaran, satuan produk, serta kata-kata umum yang tidak memiliki nilai informasi dalam proses klasifikasi transaksi. Tahap ini bertujuan untuk mengurangi noise pada data sehingga informasi penting yang merepresentasikan jenis transaksi dapat dipertahankan.

Hasil dari proses assessing dan cleaning adalah dataset yang lebih bersih, konsisten, dan siap digunakan pada tahap preprocessing lanjutan serta pemodelan machine learning untuk fitur Auto Categorization. Evaluasi kualitas data (*missing values*, duplikat, outlier)

2) Data untuk Dashboard Investasi Saham

Data saham diperoleh dari Yahoo Finance menggunakan library `yfinance` dengan cakupan saham-saham yang tergabung dalam indeks LQ45. Sebelum digunakan pada dashboard investasi, dilakukan proses data assessing untuk memastikan bahwa data historis setiap saham berhasil diperoleh dengan lengkap. Pemeriksaan dilakukan terhadap ketersediaan data perdagangan, konsistensi format tanggal, serta keberadaan nilai penutupan (*closing price*) untuk setiap saham. Apabila data suatu saham tidak tersedia atau proses pengambilan data gagal, saham tersebut tidak dimasukkan ke dalam dataset hingga data berhasil diperoleh kembali.

Selanjutnya dilakukan proses data cleaning dengan menyeragamkan format tanggal menjadi format YYYY-MM-DD, menghilangkan informasi zona waktu (*timezone*) yang

tidak diperlukan, serta memastikan seluruh nilai harga saham tersimpan dalam format numerik yang konsisten. Selain itu, dilakukan pemeriksaan data duplikat berdasarkan tanggal perdagangan. Pada proses pembaruan data harian, sistem secara otomatis membandingkan data terbaru dengan data yang telah tersimpan sebelumnya untuk mencegah terjadinya duplikasi maupun inkonsistensi nilai harga saham. Dataset yang telah bersih kemudian disimpan dalam format CSV dan digunakan sebagai sumber data utama pada dashboard investasi serta analisis pergerakan saham yang ditampilkan kepada pengguna.

3.3 Feature Engineering

1) Feature Engineering untuk Fitur Auto Categorization

Pada pengembangan fitur Auto Categorization, diterapkan tahapan Text Preprocessing Pipeline berbasis Natural Language Processing (NLP) untuk mengubah data teks transaksi menjadi format yang lebih terstruktur dan mudah dipahami oleh model machine learning. Tahapan preprocessing dilakukan secara bertahap sebagai berikut.

a) Tokenisasi

Proses tokenisasi dilakukan dengan memecah deskripsi transaksi menjadi token atau kata-kata tunggal sehingga setiap kata dapat diproses secara individual oleh sistem. Sebelum tokenisasi dilakukan, teks terlebih dahulu dinormalisasi melalui proses lowercase, penghapusan angka, tanda baca, serta spasi berlebih agar format data menjadi lebih konsisten.

b) Stopword Removal

Tahap berikutnya adalah penghapusan stopwords menggunakan kombinasi stopwords Bahasa Indonesia dari library NLTK dan custom stopwords yang disusun secara manual. Custom stopwords mencakup kata-kata promosi e-commerce, istilah pemasaran, kata sifat umum, satuan produk, serta kata-kata yang tidak memiliki pengaruh signifikan terhadap proses klasifikasi transaksi, seperti “promo”, “diskon”, “gratis ongkir”, “ready stock”, dan istilah serupa. Tahap ini bertujuan untuk mengurangi noise pada data sehingga model dapat lebih fokus pada kata-kata yang merepresentasikan jenis transaksi.

c) Stemming/Lemmatization

Proses stemming dilakukan menggunakan library Sastrawi untuk mengubah kata berimbuhan menjadi bentuk dasarnya. Tahapan ini membantu menyederhanakan variasi kata dalam Bahasa Indonesia sehingga kata-kata dengan makna serupa dapat direpresentasikan dalam bentuk yang lebih konsisten selama proses pelatihan model.

d) Vektorisasi Teks

Setelah proses preprocessing selesai dilakukan, data teks diubah menjadi representasi numerik menggunakan teknik vektorisasi agar dapat diproses oleh model machine learning. Representasi numerik ini digunakan sebagai input pada proses pelatihan model klasifikasi transaksi berbasis TensorFlow dan Scikit-learn untuk menghasilkan prediksi kategori pengeluaran secara otomatis.

2) Feature Engineering untuk Dashboard Investasi Saham

Untuk mendukung analisis investasi yang lebih komprehensif, dilakukan proses feature engineering yang diperbarui secara otomatis setiap kali data saham terbaru berhasil ditambahkan ke dalam dataset. Proses ini bertujuan menghasilkan berbagai indikator teknikal dan statistik yang dapat membantu pengguna dalam memahami kondisi pasar serta tren pergerakan saham. Fitur-fitur yang dihitung meliputi:

- a) Simple Moving Average (SMA) periode 5, 10, 20, 50, 100, dan 200 hari untuk mengidentifikasi tren harga saham.
- b) Exponential Moving Average (EMA) periode 5, 10, 20, 50, 100, dan 200 hari yang memberikan bobot lebih besar pada data harga terbaru.
- c) Moving Average Convergence Divergence (MACD) beserta signal line dan histogram untuk mendeteksi momentum dan potensi perubahan tren harga.
- d) Relative Strength Index (RSI) periode 14 hari untuk mengidentifikasi kondisi overbought dan oversold.
- e) Pivot Point, Resistance (R1–R3), dan Support (S1–S3) sebagai indikator level harga potensial yang dapat menjadi area dukungan maupun hambatan pergerakan saham.
- f) Return historis pada beberapa periode pengamatan untuk mengukur kinerja saham dari waktu ke waktu.
- g) Statistika deskriptif, meliputi rata-rata (mean), median, standar deviasi, kuartil, interquartile range (IQR), skewness, kurtosis, dan coefficient of variation (CV) untuk memberikan gambaran karakteristik distribusi harga saham.

3.4 Dataset Akhir

1) Data untuk Fitur Auto Categorization

Dataset akhir yang digunakan untuk fitur Auto Categorization terdiri atas data transaksi yang telah melalui proses pembersihan dan text preprocessing. Dataset ini memuat informasi kategori transaksi (label) serta beberapa tahapan hasil transformasi teks, seperti text cleaned, text stopwords removed, token awal, dan token akhir. Selain itu, disimpan pula informasi mengenai jumlah token sebelum dan sesudah preprocessing beserta persentase reduksi token untuk mengevaluasi efektivitas proses pembersihan teks. Dataset akhir ini digunakan sebagai sumber utama dalam proses pelatihan dan evaluasi model klasifikasi transaksi. Pada tahap pemodelan, variabel yang digunakan sebagai fitur (predictor) adalah clean_text, yaitu teks yang telah melalui seluruh tahapan preprocessing, sedangkan variabel label digunakan sebagai target kelas yang akan diprediksi oleh model.

2) Data untuk Dashboard Investasi Saham

Dataset akhir untuk dashboard investasi terdiri atas data historis saham anggota indeks LQ45 yang diperoleh dari Yahoo Finance. Dataset disusun dalam format time series dengan setiap baris merepresentasikan satu tanggal perdagangan dan setiap kolom merepresentasikan informasi harga saham, seperti harga pembukaan (Open), harga tertinggi (High), harga terendah (Low), harga penutupan (Close), serta volume perdagangan (Volume) untuk masing-masing emiten. Dataset ini digunakan sebagai sumber data utama dalam visualisasi dashboard investasi, analisis pergerakan harga saham, serta perhitungan statistika deskriptif yang ditampilkan kepada pengguna.

4. Modeling

4.1 Pemilihan Algoritma

Model klasifikasi transaksi pada fitur Auto Categorization dikembangkan menggunakan kombinasi IndoBERT dan Multi-Layer Perceptron (MLP). IndoBERT dipilih karena merupakan model bahasa Indonesia berbasis Transformer yang telah dilatih pada korpus Bahasa Indonesia dalam jumlah besar sehingga mampu menangkap makna kontekstual teks Bahasa Indonesia secara lebih mendalam dibandingkan pendekatan representasi kata konvensional. Pada penelitian ini, IndoBERT digunakan sebagai feature extractor untuk mengubah teks transaksi menjadi vektor embedding berdimensi 768.

Proses klasifikasi dilakukan menggunakan Multi-Layer Perceptron (MLP) yang dibangun menggunakan TensorFlow/Keras Functional API. Pendekatan ini memungkinkan pengembangan model yang lebih adaptif terhadap karakteristik data transaksi dibandingkan model machine learning konvensional, khususnya dalam menangkap pola non-linear pada embedding IndoBERT yang tidak dapat ditangkap oleh model linear.

Untuk mengukur keunggulan model MLP secara objektif, digunakan Regresi Logistik sebagai model baseline yang merepresentasikan pendekatan Classical Machine Learning. Regresi Logistik dipilih sebagai baseline karena merupakan algoritma klasifikasi yang umum digunakan dalam penelitian NLP, memiliki kompleksitas rendah, serta mudah diinterpretasikan. Kedua model menerima input yang identik berupa embedding IndoBERT berdimensi 768 sehingga perbandingan performa yang dihasilkan murni mencerminkan perbedaan kapasitas model, bukan perbedaan representasi fitur. Perbandingan antara MLP dan Regresi Logistik kemudian diuji secara statistik menggunakan metode A/B Testing untuk memvalidasi bahwa keunggulan MLP signifikan secara statistik dan bukan merupakan hasil kebetulan.

Arsitektur model MLP yang dikembangkan adalah sebagai berikut. Model dibangun menggunakan Functional API yang menerima input berupa embedding IndoBERT berdimensi 768. Lapisan awal terdiri atas Dense Layer dengan 512 neuron dan fungsi aktivasi ReLU yang diikuti oleh Batch Normalization dan Dropout sebesar 0,3 untuk mengurangi risiko overfitting. Selanjutnya digunakan dua buah Residual Block yang menerapkan mekanisme skip connection sehingga informasi dari lapisan sebelumnya dapat dipertahankan dengan lebih baik selama proses pembelajaran. Pada bagian akhir jaringan digunakan Dense Layer dengan 256 neuron dan lapisan output Softmax yang menghasilkan probabilitas untuk setiap kategori transaksi.

4.2 Metode Training

Proses pelatihan dan evaluasi model dilakukan dalam dua tahap eksperimen. Pertama, dibangun model baseline menggunakan Regresi Logistik sebagai representasi pendekatan Classical Machine Learning untuk memperoleh acuan performa awal. Kedua, dikembangkan model utama menggunakan arsitektur Multi-Layer Perceptron (MLP) berbasis Deep Learning yang memanfaatkan embedding IndoBERT sebagai representasi fitur teks. Kedua model dilatih dan dievaluasi menggunakan data serta test set yang identik sehingga perbandingan performa dapat dilakukan secara adil dan objektif. Hasil evaluasi dari kedua model kemudian diuji secara statistik menggunakan metode A/B Testing untuk memastikan bahwa perbedaan performa yang diperoleh bukan merupakan hasil kebetulan, melainkan mencerminkan keunggulan yang signifikan secara statistik.

- 1) Pemodelan dengan Regresi Logistik

Model baseline dibangun menggunakan algoritma Regresi Logistik dengan konfigurasi multinomial untuk mendukung klasifikasi multi-kelas. Model menerima input berupa embedding IndoBERT berdimensi 768 yang identik dengan input model MLP sehingga perbandingan performa antara kedua model murni mencerminkan perbedaan kapasitas model. Proses pelatihan menggunakan solver lbfgs dengan nilai regularisasi $C = 1,0$ dan maksimum iterasi sebesar 1.000. Tidak diterapkan pembobotan kelas khusus pada model ini sehingga model baseline belajar dari distribusi data secara alami tanpa penyesuaian tambahan.

2) Pemodelan dengan MLP

Proses pelatihan model dilakukan menggunakan pendekatan *custom training loop* berbasis TensorFlow GradientTape untuk memberikan fleksibilitas yang lebih tinggi dalam pengaturan proses optimisasi dibandingkan metode pelatihan standar. Dataset yang telah direpresentasikan dalam bentuk embedding IndoBERT dibagi menjadi data pelatihan, validasi, dan pengujian sebelum digunakan pada proses pemodelan.

Model dilatih selama 30 epoch dengan *batch size* sebesar 64 menggunakan optimizer Adam dengan *learning rate* 0,001. Untuk mengatasi potensi ketidakseimbangan jumlah data pada setiap kategori transaksi, digunakan *Focal Loss* sebagai fungsi objektif. Fungsi loss ini dirancang untuk memberikan perhatian yang lebih besar pada sampel yang sulit diklasifikasikan sehingga dapat meningkatkan kemampuan model dalam mengenali kategori dengan jumlah data yang relatif lebih sedikit.

Selain itu, model memanfaatkan beberapa komponen kustom yang dikembangkan secara khusus, yaitu *Residual Block* sebagai *custom layer* untuk membantu aliran informasi antar lapisan jaringan, *Focal Loss* sebagai *custom loss function*, serta *MetricsLogger* sebagai *custom callback* untuk mencatat perkembangan metrik pelatihan pada setiap epoch. Proses pelatihan juga diintegrasikan dengan TensorBoard untuk memantau performa model secara visual selama proses training berlangsung.

4.3 Evaluasi Model dan A/B Testing

Evaluasi model dilakukan menggunakan beberapa metrik klasifikasi, yaitu Accuracy, Precision, Recall, dan F1-Score. Selain itu, digunakan *Confusion Matrix* untuk menganalisis pola kesalahan prediksi antar kategori transaksi. Kombinasi metrik tersebut digunakan untuk memastikan bahwa model tidak hanya memiliki tingkat akurasi yang tinggi, tetapi juga mampu memberikan performa yang seimbang pada seluruh kategori pengeluaran.

Untuk memvalidasi keunggulan model MLP secara statistik, diterapkan metode A/B Testing dengan membandingkan dua variant secara terkontrol. Variant A menggunakan Regresi Logistik sebagai model baseline, sedangkan Variant B menggunakan MLP Functional API sebagai model utama. Kedua variant dilatih menggunakan data training yang sama dan dievaluasi pada test set yang identik sehingga perbedaan performa yang dihasilkan dapat dikaitkan secara langsung dengan perbedaan kapasitas model, bukan perbedaan data. Desain pengujian ini memastikan bahwa perbandingan antara kedua model dilakukan secara adil dan objektif.

Pengujian statistik dilakukan menggunakan dua metode yang saling melengkapi, yaitu Z-Test for Proportions dan McNemar's Test. Z-Test for Proportions digunakan untuk menguji apakah perbedaan accuracy antara Variant A dan Variant B signifikan secara statistik pada

tingkat signifikansi $\alpha = 0,05$. McNemar's Test digunakan untuk membandingkan performa kedua model pada level per sampel dengan memperhatikan kasus yang mana satu model benar sementara model lainnya salah sehingga pengujian ini lebih sensitif dalam mendeteksi perbedaan nyata antar model. Hipotesis yang digunakan adalah H_0 : tidak terdapat perbedaan performa yang signifikan antara kedua model, dan H_1 : terdapat perbedaan performa yang signifikan. Apabila kedua uji menghasilkan nilai p-value kurang dari 0,05, maka H_0 ditolak dan dapat disimpulkan bahwa perbedaan performa yang diperoleh bukan merupakan hasil kebetulan atau memang berbeda secara signifikan.

4.4 Model Export

Model terbaik yang diperoleh berdasarkan hasil A/B Testing disimpan dalam format .keras menggunakan mekanisme model serialization dari TensorFlow. Selain model utama, disimpan pula berbagai artefak pendukung seperti Label Encoder, konfigurasi model, tokenizer IndoBERT, dan parameter preprocessing. Seluruh artefak tersebut digunakan kembali pada tahap deployment sehingga proses inferensi dapat berjalan secara konsisten dengan proses pelatihan model.

4.5 Sistem Rekomendasi AI Based

Selain fitur klasifikasi transaksi, SAWIT juga menyediakan fitur rekomendasi keuangan personal yang mengombinasikan pendekatan rule-based dan Generative Artificial Intelligence (AI). Sistem terlebih dahulu melakukan analisis terhadap kondisi keuangan pengguna berdasarkan budget bulanan, total pengeluaran, progres waktu dalam bulan berjalan, rata-rata pengeluaran harian, proyeksi pengeluaran akhir bulan, serta kategori pengeluaran terbesar. Berdasarkan hasil analisis tersebut, sistem menentukan status keuangan pengguna ke dalam tiga tingkat peringatan (early warning), yaitu AMAN, WASPADA, dan BAHAYA.

Penentuan status dilakukan menggunakan aturan sebagai berikut:

- AMAN: Pengeluaran masih berada dalam batas wajar dan proyeksi pengeluaran akhir bulan tidak melebihi budget yang telah ditetapkan.
- WASPADA: Proyeksi pengeluaran akhir bulan diperkirakan melebihi budget atau lebih dari 80% budget telah digunakan sebelum 80% periode bulan berjalan.
- BAHAYA: Total pengeluaran telah melebihi budget atau proyeksi pengeluaran akhir bulan melebihi 120% dari budget yang tersedia.

Setelah status keuangan ditentukan, informasi tersebut dikirimkan ke model Gemini 2.5 Flash untuk menghasilkan rekomendasi keuangan yang lebih personal dan mudah dipahami oleh pengguna. Model AI akan menghasilkan ringkasan kondisi keuangan, tiga saran tindakan yang relevan, serta kalimat motivasi singkat yang disesuaikan dengan kondisi keuangan pengguna saat itu.

5. Deployment & Integrasi Sistem

5.1 Arsitektur Sistem

Arsitektur Sistem dari website SAWIT (Sahabat Duwit) dirancang dengan memisahkan antarmuka pengguna, logika *backend*, dan pemrosesan *Artificial Intelligence* (AI). Pemisahan komponen ini bertujuan agar aplikasi berjalan lebih optimal, terstruktur, dan responsif. Berikut adalah komponen utamanya:

- 1) Frontend (React + Vite + Tailwind CSS): Tampilan web interaktif untuk pengguna. React dan Vite memberikan performa *rendering* yang cepat, sementara Tailwind CSS digunakan untuk mempercepat penyusunan desain antarmuka (*styling*) agar aplikasi terlihat modern, rapi, dan responsif di berbagai ukuran layar.
- 2) Backend API (FastAPI): Bertindak sebagai pengelola utama sistem. Backend mengurus lalu lintas pengiriman data, menangani logika bisnis (seperti operasi Simpan/Edit/Hapus transaksi), dan menjembatani komunikasi antara *frontend*, *database*, dan layanan AI.
- 3) Artificial Intelligence (IndoBERT + MLP): Modul kecerdasan buatan untuk fitur kategorisasi otomatis. Saat menerima data teks dari *backend*, IndoBERT akan menerjemahkan teks tersebut menjadi representasi angka (vektor makna), lalu model jaringan saraf MLP akan memprediksi dan menentukan kategori akhir pengeluaran tersebut.
- 4) Database (Supabase PostgreSQL): Tempat penyimpanan *cloud* yang aman dan stabil untuk mengelola seluruh data pengguna dan riwayat pencatatan transaksi secara persisten.

5.2 FastAPI Endpoint

Pada proyek SAWIT, FastAPI digunakan sebagai backend utama untuk menyediakan REST API yang menghubungkan frontend, database, dan model AI. Endpoint yang dikembangkan mendukung beberapa fitur utama, seperti autentikasi pengguna, pencatatan transaksi, prediksi kategori transaksi, pengelolaan budget, wishlist calculator, subscription tracker, profil pengguna, serta rekomendasi keuangan berbasis AI.

Tabel berikut menyajikan daftar endpoint utama pada backend SAWIT beserta fungsi dari masing-masing endpoint.

Kelompok Fitur	Contoh Endpoint	Fungsi
Authentication	/api/auth/register, /api/auth/login, /api/auth/me	Mengelola registrasi, login, dan data pengguna
Transaction	/api/transactions/, /api/transactions/summary/balance	Mencatat transaksi dan menghitung saldo
AI Prediction	/api/transactions/predict-category	Memprediksi kategori transaksi dari deskripsi
Budget	/api/budget/set, /api/budget/summary/{month}	Mengatur dan menampilkan ringkasan budget
Wishlist	/api/wishlists/	Mengelola target pembelian dan estimasi tabungan
Subscription	/api/subscriptions/, /api/subscriptions/summary	Mengelola langganan dan total biaya subscription
Profile	/api/profile	Mengambil dan memperbarui data profil pengguna
AI Advice	/api/advice/	Memberikan rekomendasi dan early warning keuangan
ML Kategorisasi	/api/ml/kategorisasi	Melakukan kategorisasi beberapa teks transaksi sekaligus

Melalui endpoint-endpoint tersebut, FastAPI berperan sebagai pusat integrasi sistem SAWIT. Frontend React mengirimkan data ke backend, kemudian backend memproses data melalui database dan model AI sesuai kebutuhan. Dengan struktur endpoint yang dibagi berdasarkan fitur, sistem menjadi lebih modular, mudah diuji, dan mudah dikembangkan.

5.3 Business Dashboard (Streamlit)

1) Dashboard analitik

Dashboard analitik dikembangkan menggunakan Streamlit untuk membantu pengguna memantau kondisi keuangan secara visual dan interaktif. Data transaksi yang tersimpan pada basis data PostgreSQL diolah dan ditampilkan dalam berbagai bentuk visualisasi sehingga pengguna dapat memahami pola pemasukan dan pengeluaran secara lebih mudah. Dashboard ini terintegrasi dengan sistem transaksi dan diperbarui secara otomatis sesuai data terbaru yang dimiliki pengguna.

- Status Keuangan dan Early Warning

Dashboard dilengkapi dengan indikator status keuangan yang mengelompokkan kondisi pengguna ke dalam tiga kategori, yaitu **AMAN**, **WASPADA**, dan **BAHAYA**. Penentuan status dilakukan berdasarkan perbandingan antara budget yang tersedia, total pengeluaran saat ini, serta proyeksi pengeluaran hingga akhir bulan. Fitur ini berfungsi sebagai sistem peringatan dini agar pengguna dapat melakukan penyesuaian pengeluaran sebelum mengalami defisit anggaran.

Tampilan:





*status keuangan pada dashboard muncul hanya pada periode “bulan ini”

- Ringkasan Indikator Keuangan

Pada bagian atas dashboard ditampilkan beberapa indikator utama yang memberikan gambaran kondisi keuangan pengguna secara cepat, yaitu total pemasukan, total pengeluaran, saldo bersih, dan jumlah transaksi pada periode yang dipilih. Informasi ini membantu pengguna dalam mengevaluasi posisi keuangan secara keseluruhan tanpa perlu melakukan analisis secara manual.

Tampilan:

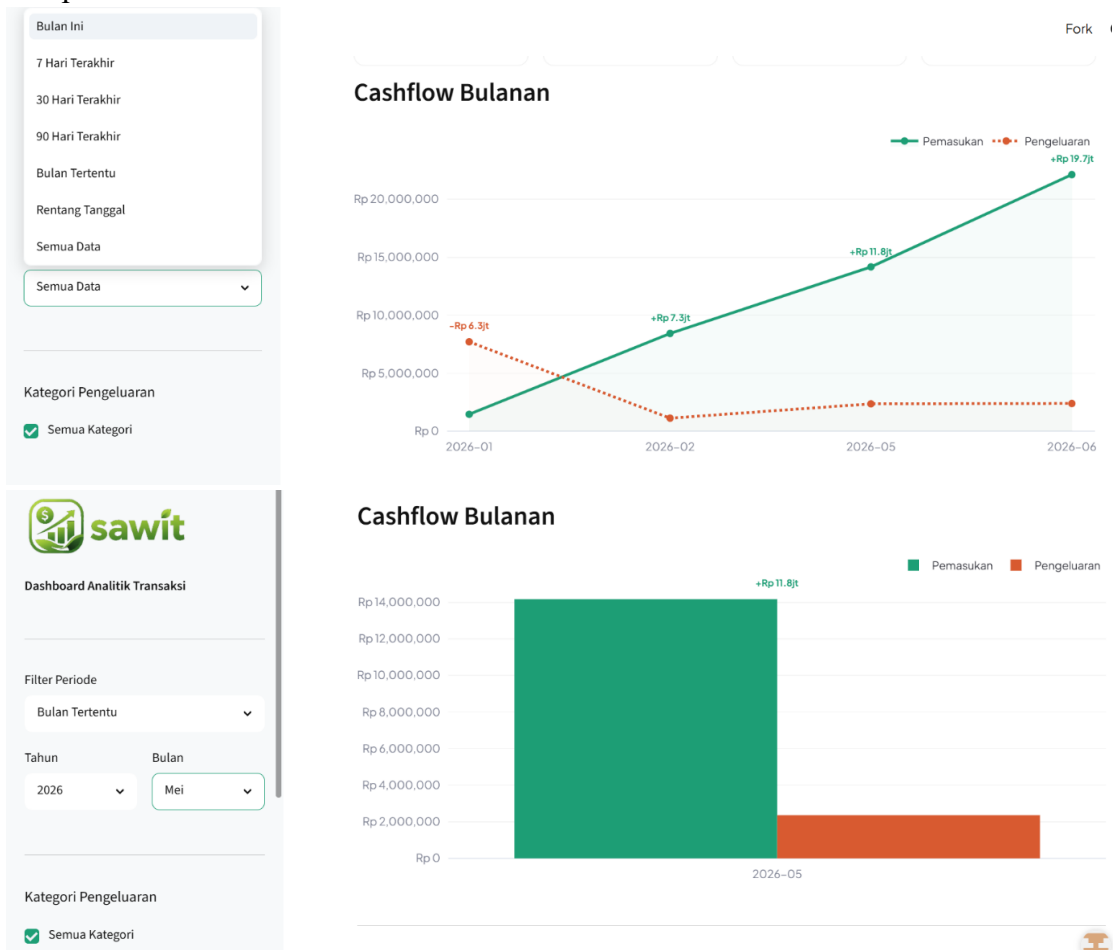




- Visualisasi cashflow bulanan

Dashboard menyediakan visualisasi *cashflow bulanan* yang menampilkan perbandingan antara total pemasukan dan total pengeluaran pada setiap periode. Visualisasi ini memungkinkan pengguna untuk memantau tren keuangan dari waktu ke waktu serta mengidentifikasi bulan dengan surplus maupun defisit keuangan. Informasi ini membantu pengguna dalam mengevaluasi efektivitas pengelolaan keuangan dan merencanakan pengeluaran pada periode berikutnya.

Tampilan:




- Breakdown kategori pengeluaran

Dashboard menampilkan komposisi pengeluaran berdasarkan kategori melalui visualisasi *donut chart*. Setiap transaksi yang telah diklasifikasikan oleh model Auto Categorization akan dikelompokkan ke dalam kategori seperti Entertainment, Konsumsi, Kesehatan, Langganan, Tagihan, dan Transportasi. Visualisasi ini membantu

pengguna memahami proporsi pengeluaran pada masing-masing kategori sehingga dapat diketahui area pengeluaran yang paling dominan.


Tampilan:



- Analisis Metode Pembayaran

Dashboard juga menyediakan analisis penggunaan metode pembayaran seperti tunai, debit, kredit, dan e-wallet. Informasi ini ditampilkan dalam bentuk grafik jumlah transaksi dan total nominal transaksi untuk setiap metode pembayaran. Analisis ini membantu pengguna memahami preferensi pembayaran yang digunakan dalam aktivitas sehari-hari.


Tampilan:



- **Budget Tracker dan Monitoring Anggaran**

Fitur Budget Tracker digunakan untuk memantau realisasi pengeluaran terhadap anggaran yang telah ditetapkan pengguna. Sistem menghitung persentase penggunaan anggaran pada setiap kategori maupun secara keseluruhan, kemudian menampilkan indikator visual untuk menunjukkan apakah pengeluaran masih berada dalam batas aman, mendekati batas anggaran, atau telah melebihi anggaran yang ditentukan.


Tampilan:



- **Deteksi kategori terboros**

Fitur Deteksi Kategori Terboros digunakan untuk mengidentifikasi kategori pengeluaran yang mengalami peningkatan terbesar dibandingkan periode sebelumnya. Sistem melakukan perbandingan antara total pengeluaran saat ini dengan periode pembandingan dan menghitung persentase perubahan pada setiap kategori. Hasil analisis ditampilkan dalam bentuk kartu ringkasan yang menunjukkan kategori dengan kenaikan pengeluaran tertinggi, nilai pengeluaran saat ini, serta persentase perubahannya. Fitur ini membantu pengguna dalam mengenali pola pengeluaran yang berpotensi menyebabkan pemborosan sehingga dapat dilakukan tindakan pengendalian sejak dini.

Tampilan:



- Riwayat Transaksi

Dashboard menyediakan tabel riwayat transaksi yang dapat difilter berdasarkan periode maupun kata kunci tertentu. Fitur ini memungkinkan pengguna untuk melakukan penelusuran transaksi secara detail sehingga memudahkan proses monitoring dan evaluasi keuangan pribadi.

Tampilan:

Tanggal	Deskripsi	Nominal	Tipe	Kategori	Metode
30 Jun 2026	Pizza / Fast Food	Rp 75,000	Pengeluaran	Konsumsi	Qris
29 Jun 2026	Isi Bensin Motor	Rp 70,000	Pengeluaran	Transportasi	Tunai
28 Jun 2026	Grab Food	Rp 44,000	Pengeluaran	Konsumsi	Debit
27 Jun 2026	Makan Bareng Teman	Rp 95,000	Pengeluaran	Konsumsi	Kredit
26 Jun 2026	Bowling	Rp 100,000	Pengeluaran	Entertainment	Qris
25 Jun 2026	Pizza / Fast Food	Rp 110,000	Pengeluaran	Konsumsi	Qris
24 Jun 2026	Kopi Kenangan / Fore	Rp 38,000	Pengeluaran	Konsumsi	Qris
23 Jun 2026	Karaoke Bareng Teman	Rp 220,000	Pengeluaran	Entertainment	Qris
22 Jun 2026	Pulsa / Paket Data	Rp 50,000	Pengeluaran	Tagihan	Debit
21 Jun 2026	Kopi Kenangan / Fore	Rp 32,000	Pengeluaran	Konsumsi	Debit

- Akses dashboard melalui web app atau dapat menuju ke link <https://dashboardtransaksi.streamlit.app/?token=<token-pengguna>>


2) Dashboard Investasi

Dashboard investasi dikembangkan menggunakan Streamlit untuk membantu pengguna memahami kondisi pasar saham Indonesia secara lebih mudah dan informatif. Dashboard memanfaatkan data historis saham-saham LQ45 yang diperbarui secara otomatis dari Yahoo Finance sehingga pengguna dapat memantau perkembangan harga saham, melakukan analisis teknikal dasar, serta memperoleh informasi pendukung dalam proses pengambilan keputusan investasi. Dashboard dirancang dengan tampilan interaktif sehingga pengguna dapat memilih saham, periode pengamatan, serta jenis visualisasi yang diinginkan.

- Monitoring Pergerakan Harga Saham Harian

Dashboard menyediakan visualisasi pergerakan harga saham dalam bentuk *line chart* maupun *candlestick chart*. Pengguna dapat memilih saham yang termasuk dalam indeks LQ45 serta menentukan rentang waktu pengamatan mulai dari 7 hari hingga 5 tahun. Visualisasi ini memungkinkan pengguna untuk mengamati tren harga, volatilitas, serta pola pergerakan saham secara historis.

Tampilan:



BBCA

PT Bank Central Asia Tbk

Keuangan Bank Bank Swasta Jakarta Pusat

> Deskripsi Perusahaan

Rp 5,525

▼ Rp 300 (-5.15%)
Per 03 Jun 2025

Grafik Harga

7D 1M 3M 1Y 5Y

Candlestick

Tampilkan SMA 20 & 50



STATISTIKA DESKRIPTIF

Rata-rata	Rp 7,407
Median	Rp 7,651
Tertinggi	Rp 8,685
Terendah	Rp 5,525
Std Deviasi	Rp 764
Q1 (25%)	Rp 6,820
Q3 (75%)	Rp 8,019
IQR	Rp 1,198
Skewness	-0.527
CV (%)	10.32%

- Informasi Profil Emiten

Setiap saham dilengkapi dengan informasi profil perusahaan yang mencakup nama perusahaan, sektor, subsektor, industri, lokasi kantor pusat, serta deskripsi bidang usaha. Informasi ini membantu pengguna memahami karakteristik perusahaan sebelum melakukan analisis lebih lanjut terhadap saham yang dipilih.

Tampilan:

BBCA

PT Bank Central Asia Tbk

Keuangan Bank Bank Swasta Jakarta Pusat

> Deskripsi Perusahaan

Kode Saham	BBCA	Bidang Usaha Utama Jasa Perbankan
Nama Perusahaan	PT Bank Central Asia Tbk	
Sektor	Keuangan	
Sub-Sektor	Bank	
Industri	Bank Swasta	
Kantor Pusat	Jakarta Pusat	

- Statistik Deskriptif Harga Saham

Dashboard menyajikan berbagai ukuran statistik deskriptif seperti rata-rata, median, harga tertinggi, harga terendah, standar deviasi, variansi, kuartil, interquartile range (IQR), skewness, kurtosis, dan coefficient of variation (CV). Statistik ini digunakan untuk memberikan gambaran mengenai distribusi harga dan tingkat volatilitas saham pada periode tertentu.

Tampilan:



- Analisis Return Historis

Sistem menghitung return historis saham untuk beberapa periode pengamatan, seperti 7 hari, 1 bulan, 3 bulan, dan 1 tahun. Informasi ini membantu pengguna mengevaluasi kinerja saham dalam berbagai horizon investasi serta membandingkan potensi keuntungan antar periode.

Tampilan:

Return Harga (Close)

PERIODE	HARGA AWAL	HARGA AKHIR	RETURN (RP)	RETURN (%)
7 Hari	Rp 5,975	Rp 5,525	▼ Rp 450	-7.53%
1 Bulan	Rp 5,900	Rp 5,525	▼ Rp 375	-6.36%
3 Bulan	Rp 6,802	Rp 5,525	▼ Rp 1,277	-18.78%
1 Tahun	Rp 8,614	Rp 5,525	▼ Rp 3,088	-35.86%

⚠ Disclaimer: Data return di atas dihitung berdasarkan data historis harga penutupan (Close) per hari terakhir yang tersedia (03 Jun 2026). Return historis tidak menjamin kinerja di masa mendatang dan tidak merupakan rekomendasi investasi.

- Analisis Moving Average

Dashboard menyediakan indikator teknikal berupa Simple Moving Average (SMA) dan Exponential Moving Average (EMA) pada beberapa periode pengamatan. Indikator ini digunakan untuk membantu pengguna mengidentifikasi arah tren harga saham dan potensi perubahan tren yang mungkin terjadi di pasar.

Tampilan:

Moving Average

Berdasarkan harga Close terakhir: Rp 5,525

Rangkuman Moving Average: **SELL** Beli: 0 - Jual: 12

PERIODE	SMA (SEDERHANA)	SINYAL SMA	EMA (EKSPONENSIAL)	SINYAL EMA
MA 5	Rp 5,800	SELL	Rp 5,754	SELL
MA 10	Rp 5,890	SELL	Rp 5,854	SELL
MA 20	Rp 5,995	SELL	Rp 5,964	SELL
MA 50	Rp 6,235	SELL	Rp 6,233	SELL
MA 100	Rp 6,718	SELL	Rp 6,610	SELL
MA 200	Rp 7,234	SELL	Rp 7,107	SELL

- Ringkasan Sinyal Analisis Teknikal

Hasil perhitungan berbagai indikator teknikal kemudian dirangkum menjadi sinyal sederhana berupa BUY, SELL, atau NEUTRAL. Ringkasan ini bertujuan membantu pengguna pemula memahami kondisi pasar dengan lebih mudah tanpa harus melakukan interpretasi indikator teknikal secara manual. Meskipun demikian, sinyal yang diberikan bersifat edukatif dan tidak dimaksudkan sebagai rekomendasi investasi secara langsung.

Tampilan:

Moving Average

Berdasarkan harga Close terakhir: Rp 5,525

Rangkuman Moving Average: **SELL** Beli: 0 - Jual: 12


PERIODE	SMA (SEDERHANA)	SINYAL SMA	EMA (EKSPONENSIAL)	SINYAL EMA
MA 5	Rp 5,800	SELL	Rp 5,754	SELL
MA 10	Rp 5,890	SELL	Rp 5,854	SELL
MA 20	Rp 5,995	SELL	Rp 5,964	SELL
MA 50	Rp 6,235	SELL	Rp 6,233	SELL
MA 100	Rp 6,718	SELL	Rp 6,610	SELL
MA 200	Rp 7,234	SELL	Rp 7,107	SELL

• Analisis MACD dan RSI

Untuk mendukung analisis teknikal, dashboard menghitung indikator MACD (*Moving Average Convergence Divergence*) beserta signal line dan histogram, serta indikator RSI (*Relative Strength Index*) periode 14 hari. Kedua indikator tersebut digunakan untuk membantu mengidentifikasi momentum pasar, kondisi overbought, oversold, serta potensi sinyal beli maupun jual.

Tampilan:

RSI — Relative Strength Index




MACD — Moving Average Convergence Divergence



- Pivot Point, Support, dan Resistance

Dashboard secara otomatis menghitung nilai Pivot Point, Support (S1–S3), dan Resistance (R1–R3) berdasarkan data harga terbaru. Informasi ini digunakan sebagai referensi dalam menentukan area support dan resistance yang berpotensi menjadi titik pembalikan maupun kelanjutan tren harga saham.

Tampilan:



5.4 Deployment Web App

Aplikasi SAWIT telah diunggah ke internet (*deploy*) agar dapat digunakan oleh publik secara *online* melalui peramban (browser).

- Tautan Akses Aplikasi (Frontend via Vercel): <https://sahabatduwit.vercel.app/>
- Tautan Akses API (Backend via Railway): <https://sawit-server-production.up.railway.app>

Alur Kerja Sistem:

- Akses Pengguna: Pengguna mengakses antarmuka web aplikasi SAWIT melalui peramban (*browser*) yang dikelola melalui platform Vercel.
- Entri Data: Pengguna memasukkan dan mengonfirmasi data transaksi pengeluaran baru melalui elemen antarmuka (*User Interface*).
- Transmisi Data: *Frontend* mengemas data transaksi tersebut dan mengirimkan *HTTP Request* menuju *server backend* (FastAPI) yang beroperasi pada infrastruktur Railway.
- Pemrosesan & Persistensi:
 - Inferensi AI: *Backend* meneruskan teks deskripsi transaksi ke modul *Artificial Intelligence* (AI) untuk memprediksi dan menentukan kategori pengeluaran secara otomatis.
 - Penyimpanan Data: Setelah label kategori dihasilkan, *Backend* menyimpan seluruh entitas data transaksi tersebut secara persisten ke dalam basis data (*database*) Supabase.
- Pembaruan Antarmuka: *Backend* mengembalikan respon status sukses kepada *frontend*. Antarmuka pengguna kemudian diperbarui (*re-rendered*) secara seketika (*real-time*) untuk menampilkan catatan transaksi yang telah terklasifikasi.

6. Hasil & Evaluasi Akhir

6.1 Performa Model Auto Categorization

- 1) Evaluasi Model Regresi Logistik (Variant A -- Baseline)

Model baseline dibangun menggunakan Regresi Logistik dengan input embedding IndoBERT berdimensi 768. Evaluasi dilakukan menggunakan metrik Accuracy, Precision, Recall, dan F1-Score untuk mengukur kemampuan model dalam mengklasifikasikan transaksi ke dalam enam kategori pengeluaran.

Metrik	Nilai
Accuracy	92,93%
Precision (Weighted)	92,67%
Recall (Weighted)	92,93%
F1-Score (Weighted)	92,67%

2) Evaluasi Model MLP (Variant B)

Model utama dikembangkan menggunakan arsitektur Multi-Layer Perceptron (MLP) berbasis TensorFlow/Keras Functional API dengan input yang identik, yaitu embedding IndoBERT berdimensi 768. Evaluasi dilakukan menggunakan metrik yang sama untuk memastikan perbandingan yang adil antara kedua model.

Metrik	Nilai
Accuracy	95,24%
Precision (Weighted)	95,06%
Recall (Weighted)	95,24%
F1-Score (Weighted)	95,06%

3) Perbandingan Model Regresi Logistik dan MLP

Hasil evaluasi menunjukkan bahwa model MLP menghasilkan performa yang lebih baik dibandingkan Regresi Logistik pada seluruh metrik evaluasi. MLP mampu mengeksplorasi pola non-linear pada embedding IndoBERT yang tidak dapat ditangkap oleh Regresi Logistik sebagai model linear. Oleh karena itu, MLP Functional API dipilih sebagai model final yang digunakan pada sistem Auto Categorization SAWIT.

Metrik	Variant A (Regresi Logistik)	Variant B (MLP Functional API)	Selisih (B – A)
Accuracy	92,93%	95,24%	+2,32%
Precision (Weighted)	92,67%	95,06%	+2,39%
Recall (Weighted)	92,93%	95,24%	+2,32%
F1-Score (Weighted)	92,67%	95,06%	+2,39%

4) A/B Testing

Untuk memastikan bahwa perbedaan performa antara Regresi Logistik dan MLP Functional API tidak terjadi secara kebetulan, dilakukan pengujian statistik menggunakan metode A/B Testing. Pada pengujian ini, Variant A adalah model Regresi Logistik sebagai baseline dan Variant B adalah model MLP Functional API sebagai model utama. Kedua model dievaluasi pada test set yang identik sehingga perbandingan dilakukan secara adil dan terkontrol.

Pengujian statistik dilakukan menggunakan dua metode, yaitu Z-Test for Proportions untuk menguji signifikansi perbedaan accuracy secara agregat, dan McNemar's Test untuk membandingkan performa kedua model pada level per sampel.

a) Z-Test for Proportions

- Hipotesis
 H_0 : Accuracy Model A = Accuracy Model B
 H_1 : Accuracy Model A $\neq$ Accuracy Model B
- Tingkat Signifikansi
 $\alpha = 0.05$
- Statistik Uji (Z-Test)
 - Accuracy A (Regresi Logistik) = 0,9293
 - Accuracy B (MLP Functional API) = 0,9524
 - Z-statistic = 7,6752
 - P-value (two-tailed) = 0,0000
- Daerah Kritik
 H_0 ditolak apabila $|Z| > 1,96$ atau p-value $< 0,05$.
- Kesimpulan
 Karena $|7,6752| > 1,96$ dan p-value = 0,0000 $< 0,05$, maka H_0 ditolak.
 Terdapat perbedaan performa yang signifikan secara statistik antara Variant A dan Variant B. Variant B (MLP Functional API) secara statistik terbukti lebih baik dibandingkan Variant A (Regresi Logistik).

b) McNemar's Test

Tabel kontingensi

	B Benar	B Salah
A Benar	11.180	171
A Salah	454	410

- Hipotesis
 H_0 : Tidak terdapat perbedaan pola prediksi yang signifikan antara Model A dan Model B
 H_1 : Terdapat perbedaan pola prediksi yang signifikan antara Model A dan Model B
- Tingkat Signifikansi
 $\alpha = 0.05$
- Statistik Uji (Chi-Square Test)
 - Chi-square statistic = 127,2384
 - P-value = 0,0000
- Daerah Kritik
 H_0 ditolak apabila chi-square $> 3,841$ atau p-value $< 0,05$.
- Kesimpulan
 Karena $127,2384 > 3,841$ dan p-value = 0,0000 $< 0,05$, maka H_0 ditolak.
 Terdapat perbedaan pola prediksi yang signifikan secara statistik antara kedua model. Variant B (MLP Functional API) lebih sering menghasilkan prediksi yang benar pada sampel yang diperdebatkan, sebanyak 457 sampel hanya benar di MLP, dibandingkan hanya 172 sampel yang hanya benar di Regresi Logistik.

5) Evaluasi Metode terbaik


Setelah metode preprocessing terbaik diperoleh, dilakukan pengembangan model final menggunakan kombinasi embedding IndoBERT dan arsitektur Multi-Layer Perceptron (MLP). Hasil evaluasi menunjukkan bahwa model memperoleh nilai Accuracy sebesar **95,03%**, Precision sebesar **95,09%**, Recall sebesar **95,03%**, dan F1-Score sebesar **95,02%**. Hasil ini berhasil melampaui target proyek yang ditetapkan, yaitu akurasi minimal 85%.

Secara keseluruhan, model Auto Categorization dengan MLP berhasil memenuhi tujuan utama proyek, yaitu melakukan klasifikasi transaksi secara otomatis dengan tingkat akurasi yang tinggi sehingga dapat mendukung pengguna dalam memperoleh pencatatan dan analisis keuangan yang lebih terstruktur.

6.2 Screenshot Produk dan Evaluasi Fitur


- Halaman autentikasi [**Lancar**]

Registrasi akun bagi pengguna baru yang memasukkan nama lengkap, email, password, dan juga konfirmasi password.



The screenshot shows the 'Create account' screen of the SAWIT application. At the top, there is a back arrow and the text 'Home'. The SAWIT logo is centered, followed by the title 'Create account' and the subtitle 'Start growing your estate'. Below this, there are four input fields: 'FULL NAME', 'EMAIL', 'PASSWORD', and 'CONFIRM PASSWORD'. Each field has a corresponding label above it. The 'PASSWORD' and 'CONFIRM PASSWORD' fields have a small eye icon to the right for toggling visibility. At the bottom of the form is a large orange button labeled 'Create Account'. Below the button, there is a link that says 'Already have an account? Sign in'.

Bagi pengguna yang sudah memiliki akun dapat langsung login hanya dengan memasukkan email dan password yang telah didaftarkan.





The screenshot shows the 'Welcome back' login screen of the SAWIT application. At the top, there is a back arrow and the text 'Home'. The SAWIT logo is centered, followed by the title 'Welcome back' and the subtitle 'Sign in to your SAWIT account'. Below this, there are two input fields: 'EMAIL' and 'PASSWORD'. Each field has a corresponding label above it. The 'PASSWORD' field has a small eye icon to the right for toggling visibility. At the bottom of the form is a large orange button labeled 'Sign in'. Below the button, there is a link that says 'Don't have an account? Create one'. Above the 'Sign in' button, there is a link that says 'Forgot password?'.


Apabila pengguna lupa akan password yang didaftarkan dapat menekan tombol “Forgot Password” dan memasukkan kembali email yang didaftarkan untuk nantinya mendapatkan konfirmasi lanjutan melalui email.

- Halaman profil dan budget input [Lancar]

Pengguna dapat menuju ke halaman profil dengan menekan ikon profil di pojok kanan



Pada bagian bawah profile, terdapat ruang bagi pengguna untuk dapat menginputkan budget yang mereka inginkan untuk masing-masing kategori.



- Fitur kategorisasi otomatis [Lancar]


Pengguna hanya perlu memasukkan deskripsi pengeluaran dan metode MLP akan langsung mengkategorikan pengeluaran tersebut pada kolom kategori.

The screenshot shows the 'Input Transaksi' form. At the top, there's a summary bar with three values: 'Rp 44.730.000', 'Rp 7.223.960', and 'Rp 37.506.040'. Below this is the form itself, which includes a 'Deskripsi' field with the placeholder 'Deskripsi transaksi', a 'Nominal' field with the value '25000', a 'Tanggal' field with the value '06/04/2026', a 'Kategori' dropdown menu with 'Konsumsi' selected, and a 'Metode' dropdown menu with 'Bank' selected. There are also buttons for 'Simpan Transaksi' and 'Batal'.


This screenshot shows the 'Deskripsi' field with the text 'beli puff pastry'. Below the field, there's a note: 'Tulis keterangan singkat agar riwayat mudah dibaca.' The 'Nominal' field is set to '25000' and the 'Tanggal' field is set to '06/04/2026'. The 'Kategori' dropdown menu is set to 'Konsumsi' and the 'Metode' dropdown menu is set to 'Bank'. There is a 'Simpan Transaksi' button at the bottom.

- Fitur Dashboard analitik [**Lancar**]


Setelah selesai login, pengguna akan langsung diarahkan ke dashboard analitik, tetapi pengguna juga dapat memilih fitur dashboard analitik pada menu bar di bagian atas.



Pengguna juga dapat melakukan filter waktu dan kategori dengan menekan tanda >> di dashboard sehingga muncul sidebar seperti pada gambar di bawah ini




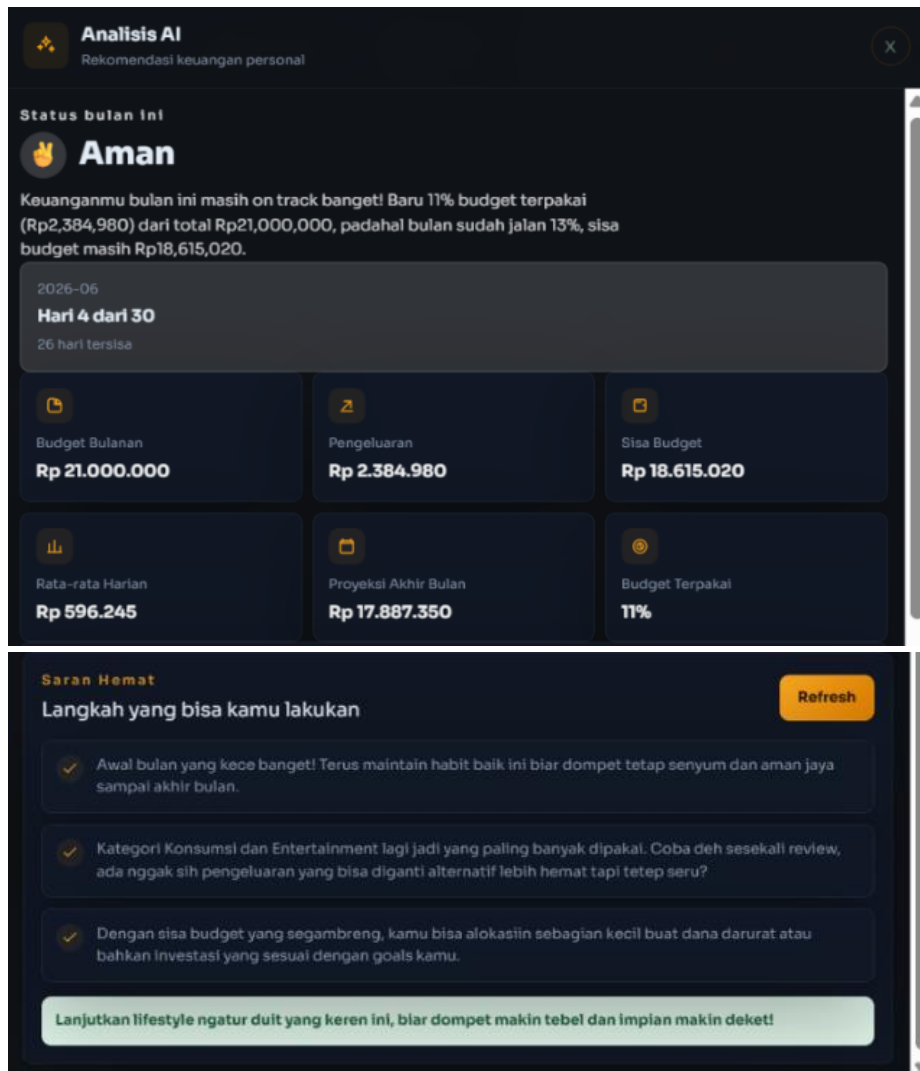
Pengguna juga dapat memperluas tampilan dashboard dengan menekan tombol “Buka Penuh” yang kemudian akan diarahkan ke tab streamlit cloud seperti pada gambar di bawah ini



- **Fitur AI Recommendation & Early Warning [Lancar]**

Pada web, terdapat ikon lingkaran di pojok kanan bawah yang dapat ditekan untuk memunculkan rekomendasi AI dan Early Warning

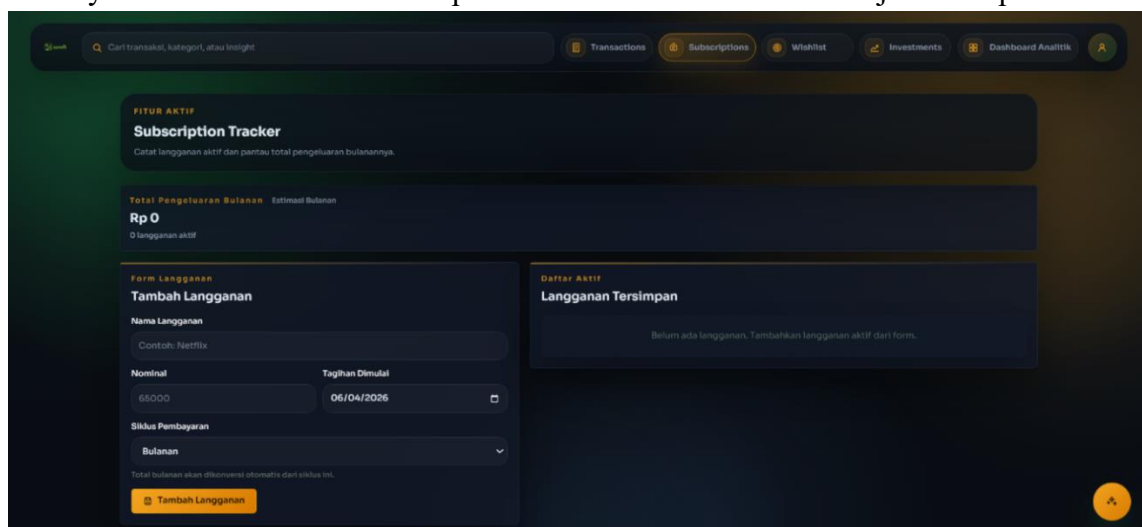




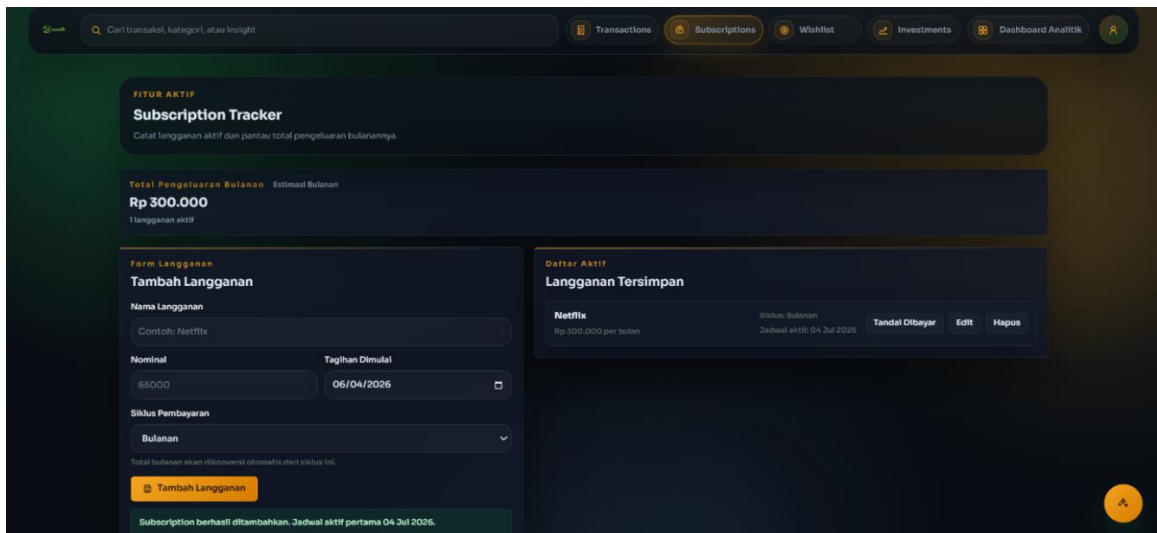
Tombol refresh dapat ditekan untuk memunculkan rekomendasi lainnya.

- Fitur subscription tracker [Lancar]

Pada fitur subscription, pengguna dapat menambahkan langganan yang mereka miliki dan nantinya sistem akan memberikan pemberitahuan ketika mendekati jatuh tempo




Berikut contoh ketika data sudah diinput dan langganan telah tersimpan

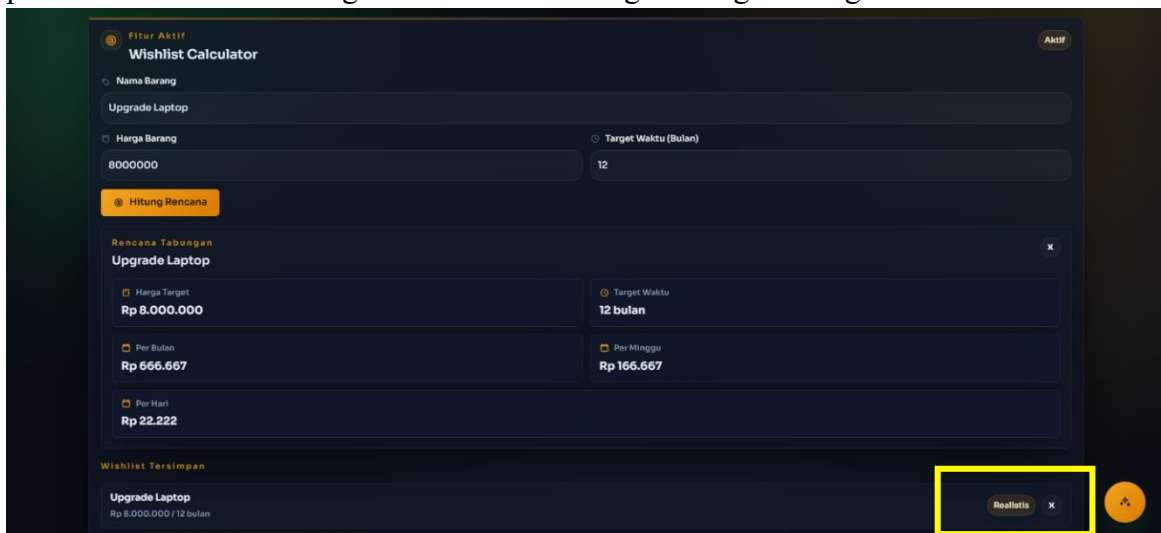



- Fitur wishlist calculator [**Lancar**]

Pengguna dapat menekan menu wishlist calculator dan dapat langsung memasukkan nama dan harga barang serta target waktu untuk mendapatkan barang tersebut




Ketika sudah menekan hitung rencana, maka akan muncul detail nominal uang yang harus ditabung atau disishkan pengguna dalam periode waktu tertentu. Ada pula keterangan perkiraan realistikitas keinginan berdasarkan harga barang dan target waktu






- Fitur Dashboard investasi [Lancar]


Pada menu dashboard investasi, pengguna akan langsung melihat dashboard streamlit untuk analisis investasi



Pengguna juga dapat memperluas tampilan dengan menekan “Buka Penuh”



- Contoh Mode Mobile Web [Lancar]



7. Conclusion

7.1 Kesimpulan

Proyek SAWIT (Sahabat Duwit) dikembangkan sebagai respons terhadap rendahnya tingkat literasi keuangan Generasi Z di Indonesia yang berada pada angka 44,04% berdasarkan SNLIK 2024. Melalui pendekatan berbasis data dan kecerdasan buatan, SAWIT berhasil menjawab keempat permasalahan bisnis yang telah dirumuskan di awal proyek.

Pertama, untuk membantu Generasi Z memahami pola pemasukan dan pengeluaran mereka, SAWIT menyediakan Dashboard Analytics yang menyajikan visualisasi cashflow bulanan, breakdown kategori pengeluaran, analisis metode pembayaran, serta deteksi kategori terboros secara otomatis. Kedua, pengelolaan transaksi harian difasilitasi melalui fitur pencatatan transaksi yang terintegrasi dengan sistem Auto Categorization berbasis AI sehingga setiap transaksi dapat diklasifikasikan secara otomatis tanpa perlu input manual dari pengguna. Ketiga, rekomendasi keuangan yang personal diwujudkan melalui fitur AI Recommendation & Early Warning yang mengombinasikan sistem rule-based untuk menentukan status keuangan (AMAN, WASPADA, atau BAHAYA) dengan model Gemini 2.5 Flash untuk menghasilkan saran tindakan yang relevan dan mudah dipahami. Keempat, peningkatan literasi investasi difasilitasi melalui Investment Corner yang menyajikan data historis saham LQ45 beserta indikator teknikal seperti MACD, RSI, dan Pivot Point dalam tampilan yang sederhana dan ramah pengguna pemula.

Dari sisi teknis, model Auto Categorization yang dibangun menggunakan kombinasi IndoBERT sebagai feature extractor dan Multi-Layer Perceptron (MLP) sebagai classifier

berhasil mencapai akurasi sebesar 95,24% pada test set yang terdiri dari 12.215 data, dilatih dari total 48.860 data training. Hasil ini melampaui target proyek yang ditetapkan sebesar minimal 85%, dan keunggulan model MLP atas baseline Logistic Regression telah divalidasi secara statistik melalui Z-Test for Proportions dan McNemar's Test dengan p-value 0,0000. Keenam fitur utama SAWIT, yakni Auto Categorization, AI Recommendation & Early Warning, Dashboard Analytics, Subscription Tracker, Wishlist Calculator, dan Investment Corner telah berhasil diimplementasikan dan berjalan sepenuhnya pada platform yang dapat diakses publik melalui <https://sahabatduwit.vercel.app/>.

7.2 Rekomendasi Action Items

Meskipun SAWIT telah berhasil dibangun dan dideploy sebagai aplikasi web yang fungsional, terdapat beberapa arah pengembangan yang dapat dilakukan untuk meningkatkan dampak dan jangkauan aplikasi ke depannya.

- 1) Mengembangkan aplikasi mobile (iOS dan Android) untuk mendukung pencatatan transaksi yang lebih cepat dan real-time mengingat Generasi Z sangat bergantung pada perangkat mobile dalam aktivitas sehari-hari.
- 2) Mengimplementasikan mekanisme active learning yang memungkinkan model belajar secara berkelanjutan dari koreksi yang diberikan oleh pengguna.
- 3) Menambahkan fitur OCR untuk struk fisik guna membuat pencatatan transaksi lebih mudah.
- 4) Menambahkan fitur chatbot sehingga pengguna dapat berinteraksi dan mendapatkan saran dengan maksimal.

8. Repository GitHub

- https://github.com/maxrumbo/CapstoneProject_CC26-PSU329